ĐẠI HỌC KINH TẾ QUỐC DÂN
VIỆN ĐÀO TẠO TIÊN TIẾN, CHẤT LƯỢNG CAO VÀ POHE

BÀI TẬP NHÓM 13

Lớp: Kinh tế đầu tư CLC 66B

Môn: Khoa học dữ liệu trong kinh tế và kinh doanh

Mã môn: AEP.TOKT1138.LS(126)_01

Giảng viên: Ts Trần Đức Minh

Mã đề: Đề 7 - Red Wine Quality

Thành viên:

1. Lê Minh - MSV: 11247688
2. Ứng Phan Trung - MSV: 11245637
3. Bùi Minh Dương - MSV: 11248226
4. Hồ Xuân Thành Hưng - MSV: 11245216
5. Nguyễn Công Tuấn Kiệt - MSV: 11240710

BẢNG ĐÁNH GIÁ CÔNG VIỆC NHÓM 13

STT	Họ và Tên	Nhiệm vụ được giao	% Hoàn thiện	Đánh giá
1	**Lê Minh**	Hoàn thiện giai đoạn 3: Phân tích và trực quan hóa	100	Tốt
2	**Hồ Xuân Thành Hưng**	Hoàn thiện giai đoạn 2: Tiền xử lý và làm sạch dữ liệu	100	Tốt
3	**Bùi Minh Dương**	Hoàn thiện giai đoạn 1: Thu thập và đánh giá dữ liệu ban đầu	100	Tốt
4	**Ứng Phan Trung**	Hoàn thiện giai đoạn 4: Đánh giá tác động và Khuyến nghị	100	Tốt
5	**Nguyễn Công Tuấn Kiệt**	Trình bày chi tiết, hoàn thiện bài	100	Tốt

MỤC LỤC

BẢNG ĐÁNH GIÁ CÔNG VIỆC NHÓM 13 ..... *2*
GIAI ĐOẠN 1: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU *4*
1.1. Nguồn dữ liệu **4**
1.2. Kiểm tra hiện trạng dữ liệu **4**
GIAI ĐOẠN 2: TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU *7*
2.1. Xử lý dữ liệu trùng lặp **7**
2.2. Giá trị khuyết thiếu: lựa chọn Mean hay Median **7**
2.3. Phát hiện và xử lý ngoại lệ (Outliers) **8**
2.4. Biến đổi dữ liệu **10**
GIAI ĐOẠN 3: PHÂN TÍCH VÀ TRỰC QUAN HÓA *11*
3.1. Câu hỏi nghiên cứu và giả thuyết **11**
3.2. Tương quan giữa các biến **11**
3.3. So sánh theo nhóm chất lượng **13**
3.4. Kết hợp hai yếu tố quan trọng nhất **15**
3.5. Kiểm định giả thuyết (t-test, Mann-Whitney và Spearman) **16**
3.6. Kiểm chứng kết quả bằng mô hình học máy **20**
3.7. Tổng hợp kết quả theo từng giả thuyết **24**
GIAI ĐOẠN 4: ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ *26*
4.1. Tóm tắt các phát hiện nổi bật **26**
4.2. Khuyến nghị ứng dụng thực tế **26**
4.3. Giới hạn của tập dữ liệu **27**
4.4. Hướng mở rộng trong tương lai **27**
KẾT LUẬN *29*
TÀI LIỆU THAM KHẢO VÀ MÃ NGUỒN *29*

GIAI ĐOẠN 1: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU

1.1. Nguồn dữ liệu

- **Tập dữ liệu:** Red Wine Quality (Cortez và cộng sự, 2009), công bố trên Kaggle: https://www.kaggle.com/datasets/uciml/red-wine-quality-cortez-et-al-2009 (bản gốc lưu tại UCI Machine Learning Repository).
- **Nội dung:** các mẫu rượu vang đỏ Vinho Verde của Bồ Đào Nha; mỗi mẫu được đo 11 chỉ số hóa lý và được chấm điểm cảm quan.
- **Cấu trúc:** 1 file winequality-red.csv gồm **1.599 quan sát × 12 thuộc tính**. Vì chỉ có một file nên không cần gộp bảng qua khóa chính/khóa ngoại.
- **Biến mục tiêu:** quality - điểm chất lượng thang 0–10 (trung vị điểm của ít nhất 3 chuyên gia).

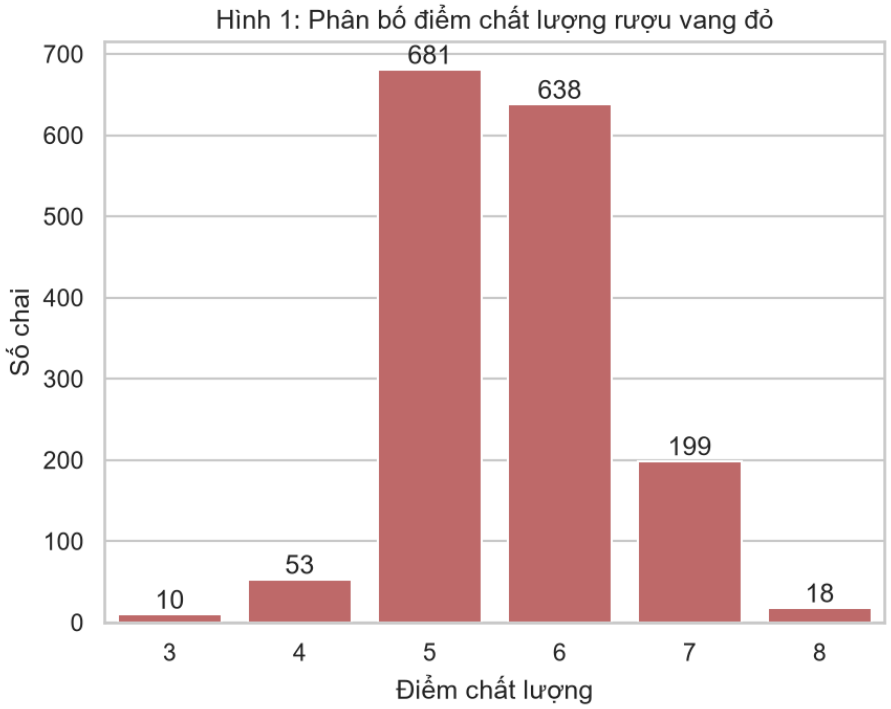
Bảng 1.1: Mô tả các thuộc tính của tập dữ liệu

Thuộc tính	**Ý nghĩa (đơn vị)**	**Giải thích**
fixed acidity	Độ axit cố định (g/dm³)	Axit không bay hơi, tạo vị chua chính
volatile acidity	Độ chua bay hơi (g/dm³)	Chủ yếu là axit axetic, quá cao gây mùi giấm
citric acid	Axit citric (g/dm³)	Tạo vị tươi, mát
residual sugar	Đường dư (g/dm³)	Đường còn lại sau lên men (độ ngọt)
chlorides	Muối clorua (g/dm³)	Tạo vị mặn
free sulfur dioxide	SO_2 tự do (mg/dm³)	Chống vi khuẩn, chống oxy hóa
total sulfur dioxide	Tổng SO_2 (mg/dm³)	SO_2 tự do + SO_2 liên kết
density	Tỷ trọng (g/cm³)	Phụ thuộc lượng cồn và đường
pH	Độ pH	Càng nhỏ càng chua
sulphates	Sulphates (g/dm³)	Chỉ số sulphates; không đồng nghĩa SO_2 bảo quản
alcohol	Nồng độ cồn (% thể tích)	Độ mạnh của rượu
quality	**Điểm chất lượng (0–10)**	**Biến mục tiêu**

1.2. Kiểm tra hiện trạng dữ liệu

Bảng 1.2: Tổng hợp kết quả kiểm tra hiện trạng dữ liệu

Tiêu chí kiểm tra	Kết quả	Đánh giá
Kích thước	1.599 dòng × 12 cột	Đủ lớn để phân tích thống kê
Kiểu dữ liệu	11 cột float64, quality là int64	Đúng với ý nghĩa, không cần chuyển định dạng
Giá trị khuyết thiếu	0% ở tất cả các cột	Dữ liệu đầy đủ
Dòng trùng lặp	240 dòng (15%)	**Cần xử lý**
Giá trị bất thường	Max lớn hơn nhiều so với Q3 ở residual sugar (2,6 → 15,5), chlorides (0,09 → 0,61), total SO_2 (62 → 289), sulphates (0,73 → 2,0)	**Nghi có outlier, cần kiểm tra**
Phạm vi điểm quality	Chỉ từ 3 đến 8, trung bình 5,64	Không có điểm cực thấp/cực cao



Hình 1: Phân bố điểm chất lượng rượu vang đỏ

Phân tích:

- Dữ liệu **mất cân bằng mạnh**: điểm 5 và 6 chiếm **82,5%** tổng số mẫu (42,6% và 39,9%). Rượu ngon (điểm 7–8) chỉ chiếm **13,5%**, rượu kém (điểm 3–4) chỉ **3,9%**.
- Điểm 3 chỉ có 10 mẫu, điểm 8 chỉ có 18 mẫu (dữ liệu gốc; sau khi xóa dòng trùng còn 10 và 17 mẫu) → so sánh từng mức điểm riêng lẻ ở hai đầu thang điểm sẽ kém tin cậy.

- **Vì vậy, nhóm gộp điểm** thành 3 nhóm chất lượng và so sánh bằng tỷ lệ %, giá trị trung bình thay vì số lượng tuyệt đối.

GIAI ĐOẠN 2: TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU

2.1. Xử lý dữ liệu trùng lặp

Minh chứng: hàm df.duplicated() ghi nhận 240 dòng có cùng giá trị ở cả 12 cột. Đây là các bản ghi trùng theo thuộc tính, chưa đủ cơ sở khẳng định chắc chắn là cùng một chai vì dữ liệu thiếu mã định danh mẫu.

Giải pháp được nhóm lựa chọn: drop_duplicates(), còn 1.359 quan sát. Việc xóa trùng được coi là giả định tiền xử lý và cần đánh giá độ nhạy kết quả khi giữ các quan sát trùng thuộc tính.

Giải trình: các dòng có cùng giá trị đo có thể là ghi lặp nhưng cũng có thể là mẫu hợp lệ. Vì vậy cần tránh khẳng định chắc chắn chúng là lỗi nhập liệu.

2.2. Giá trị khuyết thiếu: lựa chọn Mean hay Median

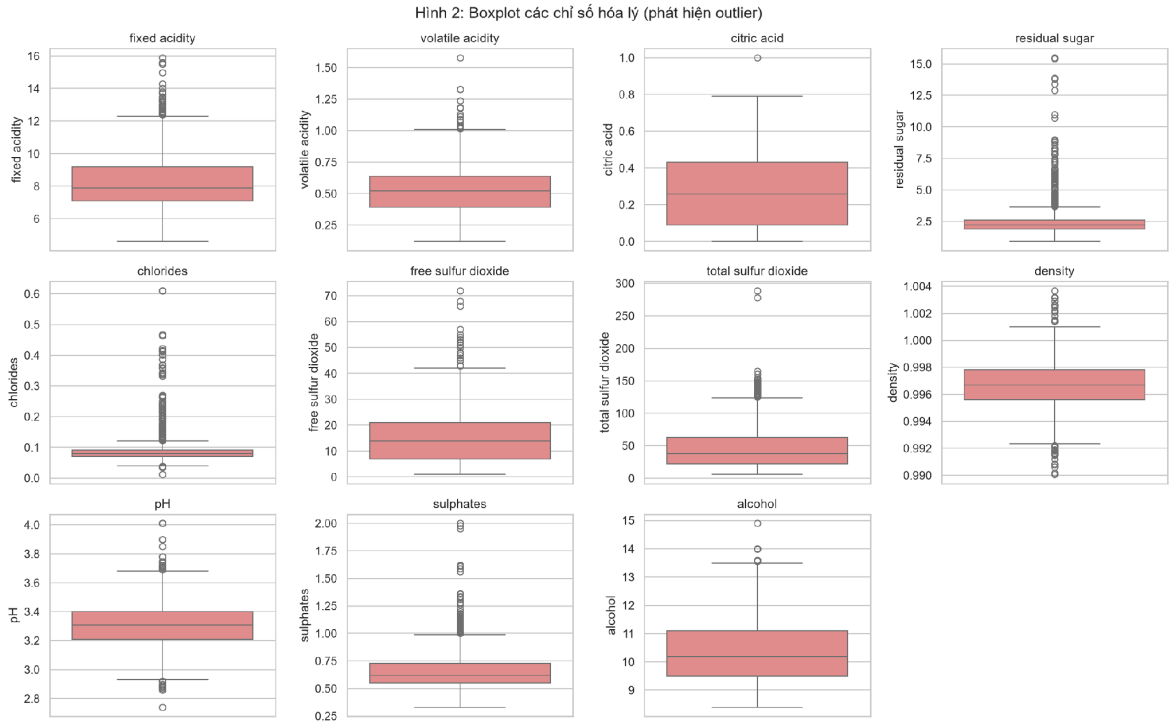
Dữ liệu không có giá trị thiếu nên không cần điền. Tuy nhiên, nhóm vẫn so sánh Mean, Median và độ lệch (Skew) của từng biến để xác định phương án phù hợp nếu cần điền, đồng thời làm cơ sở cho việc xử lý ngoại lệ.

Bảng 2.1: So sánh Mean – Median của một số biến tiêu biểu (sau khi xóa trùng)

Biến	Mean	Median	Skew
chlorides	0,09	0,08	5,50
residual sugar	2,52	2,20	4,55
sulphates	0,66	0,62	2,41
total sulfur dioxide	46,83	38,00	1,54
free sulfur dioxide	15,89	14,00	1,23
alcohol	10,43	10,20	0,86
pH	3,31	3,31	0,23

Giải trình: 5 biến có Skew > 1 (lệch phải mạnh), ở đó Mean lớn hơn Median rõ rệt (ví dụ total sulfur dioxide: Mean 46,8 so với Median 38). Nguyên nhân là một số ít mẫu có giá trị rất lớn kéo trung bình lên. Vì vậy, nếu có dữ liệu thiếu, nhóm sẽ dùng **Median** để điền vì Median không bị ảnh hưởng bởi giá trị cực đoan và đại diện tốt hơn cho mẫu điển hình.

2.3. Phát hiện và xử lý ngoại lệ (Outliers)



Hình 2: Boxplot 11 chỉ số hóa lý (các chấm ngoài râu là outlier)

Nhóm sử dụng **phương pháp IQR**: một giá trị là outlier nếu nhỏ hơn Q1 − 1,5×IQR hoặc lớn hơn Q3 + 1,5×IQR (IQR = Q3 − Q1). Phương pháp này dựa trên tứ phân vị nên phù hợp với các biến lệch như trong dữ liệu này.

Bảng 2.2: Số lượng outlier theo phương pháp IQR

Biến	Số outlier	Tỷ lệ (%)
residual sugar	126	9,3
chlorides	87	6,4
sulphates	55	4,0
total sulfur dioxide	45	3,3
fixed acidity	41	3,0
density	35	2,6
pH	28	2,1
free sulfur dioxide	26	1,9
volatile acidity	19	1,4
alcohol	12	0,9
citric acid	1	0,1

Phân tích:

- Outlier tập trung ở các biến lệch phải mạnh: residual sugar (9,3%), chlorides (6,4%), sulphates (4,0%). Tổng cộng **340/1.359 chai (25%)** có ít nhất một chỉ số là outlier.
- So sánh phân bố điểm: nhóm chai có outlier có tỷ lệ **điểm 3 là 2,1%**, cao gấp 7 lần nhóm không có outlier (0,3%); tỷ lệ **điểm 7 là 15,3%** so với 11,3%.

Quyết định: giữ lại outlier. Lý do: (1) các giá trị lớn nhất vẫn có thể xảy ra trong thực tế (rượu hơi ngọt, rượu dùng nhiều chất bảo quản), không có giá trị vô lý như số âm; (2) xóa sẽ mất 25% dữ liệu; (3) outlier tập trung ở hai đầu chất lượng, nếu xóa đi sẽ mất phần lớn mẫu rượu kém; (4) các công cụ phân tích ở Giai đoạn 3 (boxplot, median, Welch t-test trên nhóm lớn) ít bị outlier ảnh hưởng.

Kiểm tra độ nhạy: để xem hai quyết định làm sạch (xóa trùng, giữ outlier) không làm thay đổi kết luận, nhóm tính lại hệ số tương quan của 4 chỉ số trong giả thuyết H1–H4 với điểm chất lượng trên 3 phiên bản dữ liệu (Bảng 2.3).

Bảng 2.3: Phân tích độ nhạy, hệ số tương quan với quality

Chỉ tiêu	Dữ liệu gốc (chưa xóa trùng)	Đã xóa trùng (bản dùng chính)	Xóa trùng + bỏ chai có outlier
Số chai	1.599	1.359	1.019
Tỷ lệ rượu ngon (%)	13,6	13,5	12,4
r (alcohol, quality)	+0,476	+0,480	+0,515
r (volatile acidity, quality)	−0,391	−0,395	−0,353
r (sulphates, quality)	+0,251	+0,249	+0,423
r (residual sugar, quality)	+0,014	+0,014	+0,018

Phân tích:

- **Xóa dòng trùng** gần như không làm đổi kết quả (alcohol +0,476 → +0,480; volatile acidity −0,391 → −0,395; sulphates +0,251 → +0,249): các mẫu không còn bị đếm hai lần và kết luận vẫn giữ nguyên.
- Loại mọi chai có ít nhất một ngoại lệ (1.359 → 1.019 chai) không đổi chiều của bốn hệ số tương quan; tuy nhiên, độ lớn của một số quan hệ thay đổi đáng kể, đặc biệt là sulphates (+0,249 → +0,423). Không thể kết luận kết quả hoàn toàn không phụ thuộc vào cách xử lý ngoại lệ.
- **Tuy nhiên, tương quan của sulphates tăng mạnh** từ +0,249 lên +0,423 và vượt lên trên volatile acidity, vì các chai có sulphates rất cao chủ yếu là rượu kém (mục

3.3). Nếu xóa các chai này, tương quan của sulphates sẽ cao hơn thực tế và nhóm sẽ không thấy được việc dùng quá nhiều sulphates không làm rượu ngon hơn. Bỏ outlier cũng làm tỷ lệ rượu ngon giảm từ 13,5% xuống 12,4%.

- Nhóm giữ lại outlier để bảo toàn dữ liệu, đồng thời ghi nhận rằng mức độ tương quan và thứ hạng biến có thể nhạy với cách xử lý. Cần đánh giá độ nhạy của kết quả mô hình.

2.4. Biến đổi dữ liệu

Tạo biến nhóm chất lượng bằng pd.cut: Thấp (điểm ≤ 5) gồm 640 mẫu; Trung bình (điểm 6) gồm 535 mẫu; Cao (điểm ≥ 7) gồm 184 mẫu. Lý do: các mức điểm 3, 4, 8 có quá ít mẫu, gộp nhóm giúp so sánh ổn định hơn; mốc 7 là ngưỡng thường dùng để xác định rượu ngon.

Không cần mã hóa (encoding): tất cả các biến đều là số, không có biến phân loại dạng chữ nên không cần One-hot hay Label Encoding.

Không cần chuẩn hóa (scaling): Giai đoạn 3 chỉ so sánh từng biến giữa các nhóm và tính hệ số tương quan - các phép tính này không phụ thuộc vào đơn vị đo. Chuẩn hóa chỉ cần thiết khi đưa nhiều biến khác đơn vị vào cùng một mô hình học máy. Mô hình kiểm chứng ở mục 3.6 là Random Forest - mô hình chia dữ liệu bằng các câu hỏi ngưỡng nên cũng không bị ảnh hưởng bởi đơn vị đo, không cần chuẩn hóa.

GIAI ĐOẠN 3: PHÂN TÍCH VÀ TRỰC QUAN HÓA

3.1. Câu hỏi nghiên cứu và giả thuyết

Câu hỏi nghiên cứu: Chỉ số hóa lý nào phân biệt rượu ngon với rượu thường? Trước khi phân tích, nhóm đặt ra 4 giả thuyết dựa trên hiểu biết chung về rượu vang:

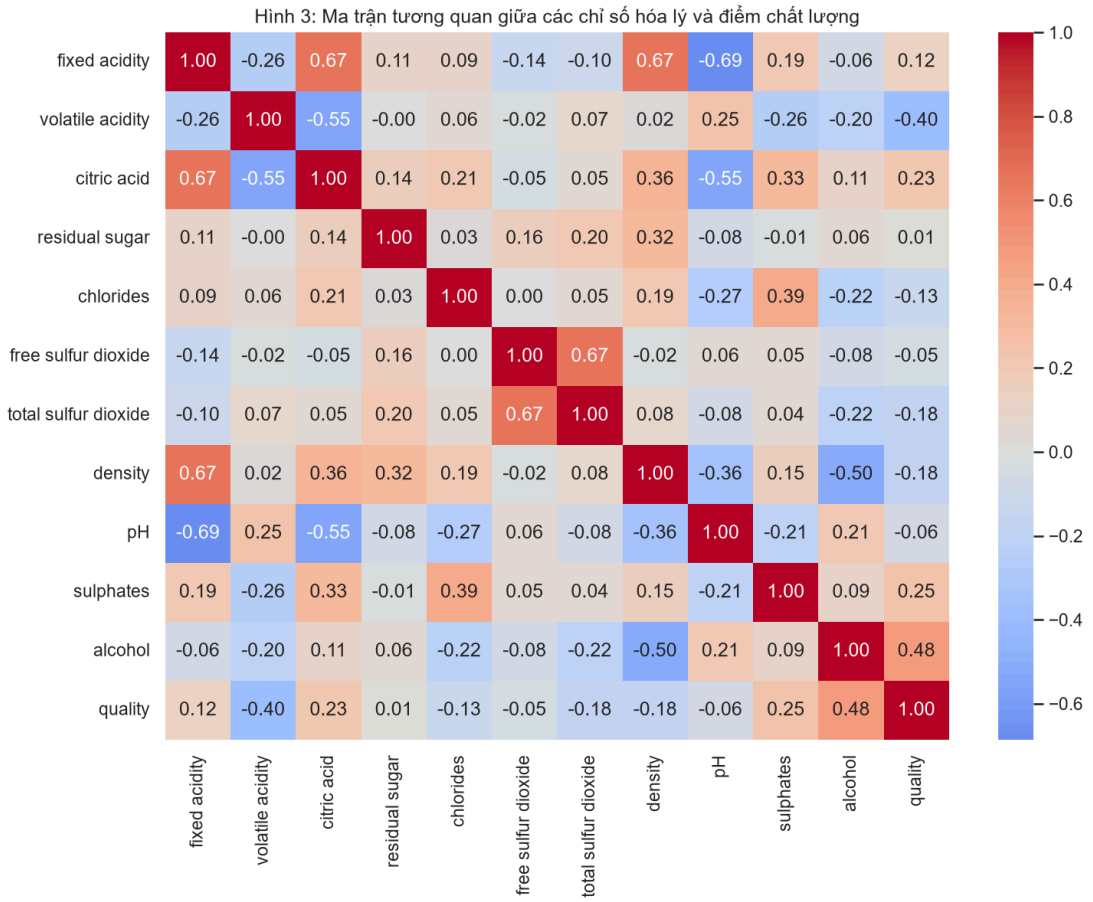
Bảng 3.1: Các giả thuyết nghiên cứu

Giả thuyết	Nội dung	Kỳ vọng
H1	Rượu có nồng độ cồn cao hơn được chấm điểm cao hơn	Tương quan dương
H2	Rượu có độ chua bay hơi (mùi giấm) cao bị chấm điểm thấp hơn	Tương quan âm
H3	Rượu có sulphates (chất bảo quản) cao hơn được chấm điểm cao hơn	Tương quan dương
H4	Đường dư (độ ngọt) không ảnh hưởng đáng kể đến điểm rượu vang đỏ	Chưa đủ bằng chứng về khác biệt

Quy trình kiểm tra: tương quan (Hình 3–4) → so sánh theo nhóm (Hình 5–6) → kết hợp hai yếu tố (Hình 7) → kiểm định thống kê (mục 3.5) → kiểm chứng bằng mô hình (mục 3.6) → tổng hợp theo từng giả thuyết (mục 3.7).

3.2. Tương quan giữa các biến

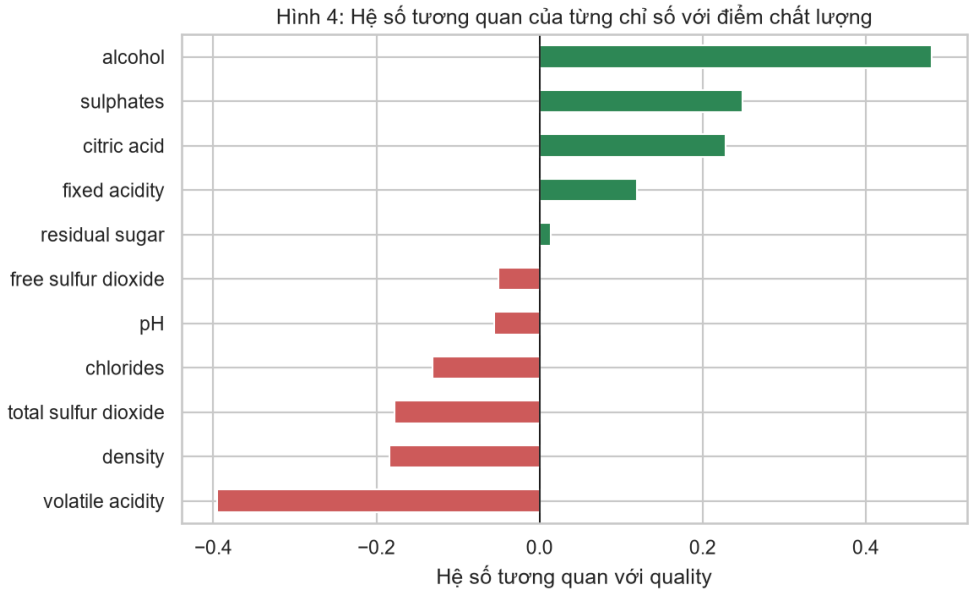
Lý do chọn biểu đồ: heatmap cho xem cùng lúc tương quan của tất cả các cặp biến, nhờ đó nhóm chọn ra được các biến liên quan nhiều đến điểm chất lượng và các biến đi cùng nhau.



Hình 3: Ma trận tương quan giữa các chỉ số hóa lý và điểm chất lượng

Phân tích:

- Trong mẫu nghiên cứu, alcohol (+0,48) và volatile acidity (−0,39) có tương quan tuyến tính với quality mạnh nhất theo trị tuyệt đối; tiếp theo là sulphates (+0,25) và citric acid (+0,23). Đây là quan hệ thống kê, không chứng minh tác động nhân quả.
- Các biến về axit đi cùng nhau: fixed acidity với pH (−0,69), với citric acid (+0,67), với density (+0,67); free và total SO_2 tương quan +0,67.
- Alcohol và density có tương quan −0,50. Vì các biến hóa lý cùng liên hệ với nhau, tương quan đơn biến chưa đủ xác định vai trò riêng của density; cần mô hình đa biến để kiểm tra.



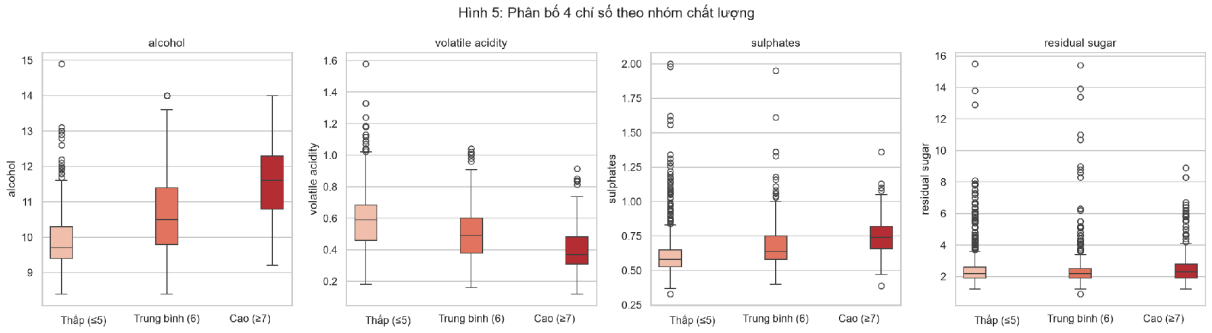
Hình 4: Hệ số tương quan của từng chỉ số với điểm chất lượng

Phân tích:

- Thứ tự độ lớn tương quan đơn biến: alcohol > volatile acidity > sulphates > citric acid (theo trị tuyệt đối); không phải thứ tự mức tác động nhân quả.
- Residual sugar có tương quan gần bằng 0 (**+0,014**) → ủng hộ H4. Free SO_2 (−0,05) và pH (−0,06) cũng hầu như không liên quan đến điểm.
- **Ý nghĩa thực tế: khi kiểm soát chất lượng, doanh nghiệp có thể ưu tiên theo dõi 3–4 chỉ số này trước.**

3.3. So sánh theo nhóm chất lượng

Lý do chọn biểu đồ: boxplot thể hiện cả trung vị, độ phân tán và outlier của từng nhóm, phù hợp để so sánh phân phối của một biến số giữa các nhóm.



Hình 5: Phân bố 4 chỉ số theo nhóm chất lượng

Bảng 3.2: Giá trị trung bình của 4 chỉ số theo nhóm chất lượng

Nhóm chất lượng	Alcohol (%)	Volatile acidity	Sulphates	Residual sugar
Thấp (≤5)	9,921	0,593	0,620	2,527
Trung bình (6)	10,659	0,496	0,675	2,457
Cao (≥7)	11,553	0,406	0,746	2,704

Phân tích:

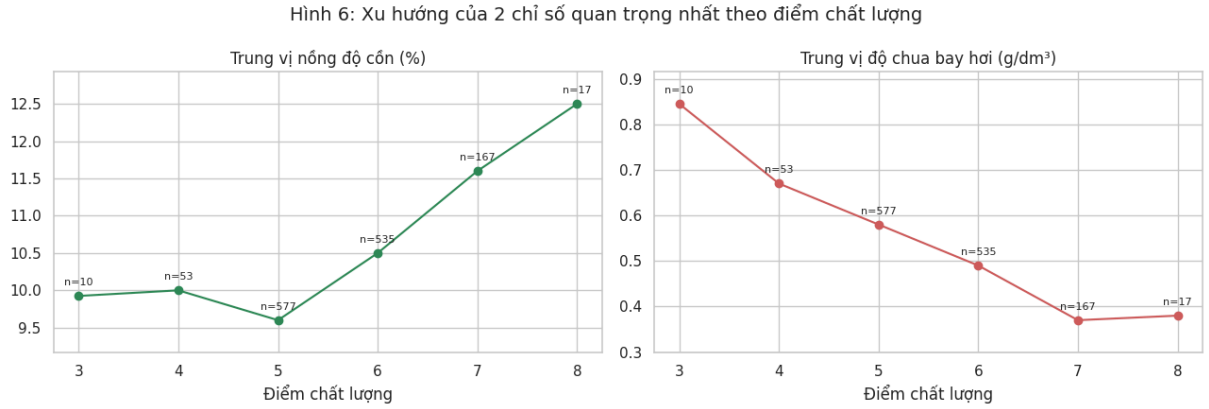
- **H1 – Nồng độ cồn** tăng đều qua 3 nhóm (9,92% → 10,66% → 11,55%); hộp của nhóm Cao nằm gần như hoàn toàn phía trên trung vị của nhóm Thấp.
- **H2 – Độ chua bay hơi** giảm đều (0,593 → 0,496 → 0,406): rượu nhóm Cao có mùi giấm ít hơn nhóm Thấp khoảng **32%**.
- **H3 – Sulphates** tăng (0,620 → 0,675 → 0,746). Riêng các giá trị sulphates rất cao (1,5–2,0) lại nằm chủ yếu ở nhóm Thấp (5/7 chai, không chai nào thuộc nhóm Cao) → gợi ý rằng dùng **quá nhiều** sulphates chưa chắc làm rượu ngon hơn. Nhóm kiểm tra thêm điều này ở Bảng 3.3.
- H4 – Residual sugar không có xu hướng đơn điệu rõ ràng qua các nhóm trong biểu đồ. Kết quả mô tả này chưa đủ để kết luận đường dư không có liên quan hoặc tác động bằng không.

Bảng 3.3: Điểm trung bình và tỷ lệ rượu ngon (điểm ≥ 7) theo khoảng sulphates

Khoảng sulphates (g/dm³)	Số chai	Điểm trung bình	Tỷ lệ rượu ngon (%)
≤ 0,55	357	5,23	3,4
0,55 – 0,65	465	5,52	7,3
0,65 – 0,75	250	5,92	21,2
0,75 – 0,85	156	6,19	34,6
0,85 – 1,0	77	6,04	28,6
> 1,0	54	5,57	16,7

- **Sulphates – kiểm tra thêm (Bảng 3.3):** tỷ lệ rượu ngon tăng dần từ 3,4% (≤ 0,55) lên cao nhất 34,6% ở khoảng 0,75–0,85 (điểm trung bình cũng cao nhất: 6,19), nhưng giảm còn 28,6% ở khoảng 0,85–1,0 và chỉ 16,7% khi sulphates > 1,0 (điểm trung bình 5,57) - thấp hơn cả khoảng 0,65–0,75.
- Bảng 3.3 cho thấy tỷ lệ rượu ngon trong mẫu quan sát cao nhất ở khoảng sulphates 0,75–0,85 g/dm³, sau đó giảm. Không thể dùng bảng này để xác định nồng độ tối ưu hay khuyến nghị thay đổi công thức sản xuất; nhóm >1,0 chỉ có 54 mẫu.

Lý do chọn biểu đồ đường (Hình 6): thể hiện xu hướng thay đổi theo thứ tự điểm 3 → 8. Nhóm vẽ trung vị (không dùng trung bình vì dữ liệu lệch phải, xem mục 2.2) và ghi số chai n tại mỗi mức điểm.



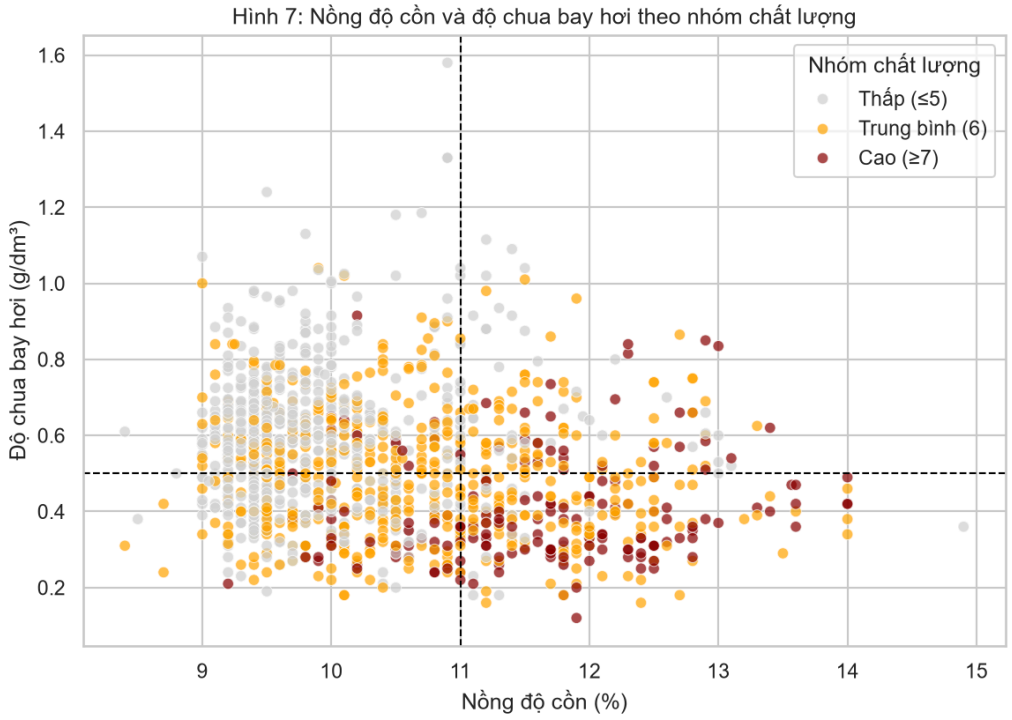
Hình 6: Xu hướng của nồng độ cồn và độ chua bay hơi theo điểm chất lượng

Phân tích:

- Nồng độ cồn **đi ngang** ở điểm 3–5 (trung vị khoảng 9,6–10,0%), sau đó **tăng mạnh** từ điểm 6: 10,5% → 11,6% → 12,5% (điểm 8).
- Độ chua bay hơi **giảm đều**: 0,845 (điểm 3) → 0,67 → 0,58 → 0,49 → 0,37 (điểm 7); điểm 8 gần như bằng điểm 7 (0,38).
- **Lưu ý cỡ mẫu:** điểm 3 chỉ có 10 chai và điểm 8 chỉ có 17 chai nên giá trị ở hai đầu kém ổn định - ví dụ, trung vị cồn ở điểm 3–4 (9,9–10,0%) nhỉnh hơn điểm 5 (9,6%) có thể chỉ là dao động ngẫu nhiên.
- Hình 6 gợi ý hai kiểu liên hệ khác nhau theo từng mức điểm. Khái niệm "điểm cộng/điểm trừ" chỉ là cách mô tả khám phá dữ liệu, không phải bằng chứng rằng điều chỉnh các chỉ số sẽ làm thay đổi điểm chất lượng.

3.4. Kết hợp hai yếu tố quan trọng nhất

Lý do chọn biểu đồ: biểu đồ phân tán (scatter plot) thể hiện đồng thời hai biến số và màu sắc theo nhóm, giúp tìm vùng tập trung của rượu ngon.



Hình 7: Nồng độ cồn và độ chua bay hơi theo nhóm chất lượng

Phân tích:

- Rượu nhóm Cao (đỏ đậm) tập trung ở **góc dưới bên phải** (nhiều cồn, ít vị giấm); rượu nhóm Thấp (xám) tập trung ở góc trên bên trái.
- "Vùng rượu ngon" (cồn > 11% và độ chua bay hơi < 0,5) chỉ gồm 222 chai (16,3%) nhưng có tỷ lệ rượu ngon 43,2%, so với 7,7% ở ngoài vùng - cao gấp khoảng 5,6 lần. Vùng này chứa 52,2% tổng số rượu ngon. Khi áp dụng nguyên quy tắc trên tập test (272 mẫu), vùng này chọn 45 mẫu, Precision 40,00%, Recall 48,65% và F1 43,90%. Vì ngưỡng được lựa chọn sau khi quan sát dữ liệu toàn bộ, phép kiểm tra này vẫn chỉ mang tính mô tả, chưa phải xác thực độc lập.
- **Ứng dụng: chỉ cần 2 chỉ số này là có thể sàng lọc nhanh để ưu tiên các lô rượu có khả năng đạt điểm cao.**
- Hai ngưỡng alcohol >11% và volatile acidity <0,5 được lựa chọn sau khi xem dữ liệu, rồi đánh giá trên chính dữ liệu ấy. Vì thế tỷ lệ 43,2% là kết quả trong mẫu và có thể lạc quan; cần đánh giá độc lập trước khi triển khai.

3.5. Kiểm định giả thuyết (t-test, Mann-Whitney và Spearman)

Để kiểm chứng các khác biệt quan sát được không phải do ngẫu nhiên, nhóm chia dữ liệu thành **rượu ngon** (điểm ≥ 7, 184 mẫu) và **rượu thường** (điểm ≤ 6, 1.175 mẫu), rồi dùng **Welch t-test** so sánh trung bình hai nhóm. Welch t-test được chọn thay cho t-test thông thường vì hai nhóm có cỡ mẫu chênh lệch lớn và độ phân tán khác nhau. Mức ý nghĩa α = 5%: nếu p-value < 0,05 thì khác biệt có ý nghĩa thống kê.

Bảng 3.4: Kết quả kiểm định Welch t-test

Giả thuyết	Rượu ngon và rượu thường	Chênh lệch	p-value	Kết luận
H1 – Alcohol	11,55 và10,26	+12,6%	$2{,}0\times10^{-40}$	Được ủng hộ
H2 – Volatile acidity	0,406 và 0,549	−26,0%	$6{,}5\times10^{-28}$	Được ủng hộ
H3 – Sulphates	0,746 và 0,645	+15,6%	$1{,}9\times10^{-17}$	Có tương quan dương; chưa có mức tối ưu
H4 – Residual sugar	2,70 và 2,50	+8,4%	0,056	Chưa đủ bằng chứng ở mức 5% (không đủ bằng chứng về khác biệt)

Phân tích:

- H1, H2, H3 có p-value rất nhỏ (nhỏ hơn 0,05 rất nhiều) → khác biệt giữa hai nhóm có ý nghĩa thống kê.
- H4 có p-value Welch = 0,056 > 0,05: chưa đủ bằng chứng để bác bỏ giả thuyết không có khác biệt trung bình ở mức ý nghĩa 5%. Điều này không chứng minh hai nhóm tương đương.
- Kết quả H4 cũng có tương quan đơn biến gần 0 và các hộp phân phối chồng lấp. Nhóm chỉ kết luận chưa phát hiện mối liên hệ rõ ràng theo các phép phân tích đã áp dụng, không khẳng định đường dư không tác động đến chất lượng.
- Ngoài p-value, nhóm xem thêm độ lớn của chênh lệch: độ chua bay hơi chênh lệch tương đối nhiều nhất (−26%), còn nồng độ cồn có tương quan mạnh nhất.

Kiểm tra độ vững của kết quả

t-test giả định dữ liệu của mỗi nhóm gần phân phối chuẩn. Nhóm kiểm tra giả định này bằng **kiểm định Shapiro-Wilk** (p-value < 0,05 nghĩa là dữ liệu không có phân phối chuẩn):

Bảng 3.5: Kiểm tra phân phối chuẩn (Shapiro-Wilk)

Biến	p-value (rượu ngon)	p-value (rượu thường)	Cả 2 nhóm đều chuẩn?
alcohol	0,2901	≈ 0	Không
volatile acidity	≈ 0	≈ 0	Không
sulphates	0,0004	≈ 0	Không
residual sugar	≈ 0	≈ 0	Không

Kiểm định Shapiro–Wilk cho thấy nhiều nhóm không có phân phối chuẩn theo ngưỡng $p < 0,05$. Với cỡ mẫu lớn, Welch t-test vẫn có thể tương đối vững, nhưng cần xem cả đặc điểm phân phối, outlier và khoảng tin cậy. Mann–Whitney kiểm tra khác biệt về phân bố thứ hạng, không mặc nhiên là phép kiểm định trung vị.

Bảng 3.6: Kiểm tra lại bằng Mann-Whitney U

Biến	Trung vị rượu ngon	Trung vị rượu thường	p-value Mann-Whitney	Kết luận	Giống t-test?
alcohol	11,6	10,0	$1,2\times10^{-45}$	Khác biệt	Có
volatile acidity	0,37	0,54	$8,0\times10^{-27}$	Khác biệt	Có
sulphates	0,74	0,60	$1,9\times10^{-26}$	Khác biệt	Có
residual sugar	2,3	2,2	0,054	Chưa đủ bằng chứng về khác biệt	Có

Phân tích:

- Mann–Whitney U ghi nhận bằng chứng về khác biệt phân bố thứ hạng đối với alcohol, volatile acidity và sulphates; đối với residual sugar, $p \approx 0,054$ chưa đủ bằng chứng ở mức 5%. Không được diễn giải thành hai nhóm hoàn toàn giống nhau.
- Như vậy, kết luận không thay đổi khi chuyển sang kiểm định không cần giả định phân phối chuẩn.

Kiểm tra lại bằng Spearman: t-test và Mann-Whitney chỉ so 2 nhóm (ngon và thường), tức là coi điểm 3 và điểm 6 như nhau. Tương quan Spearman dùng toàn bộ thang điểm 3–8 và chỉ dựa vào thứ tự xếp hạng - phù hợp vì quality là điểm xếp hạng của chuyên gia.

Bảng 3.7: Tương quan Spearman trên toàn thang điểm (kèm hệ số Pearson)

Biến	ρ Spearman	r Pearson	p-value (Spearman)	Kết luận
alcohol	+0,488	+0,480	$3,2\times10^{-82}$	Có quan hệ
volatile acidity	−0,387	−0,395	$6,5\times10^{-50}$	Có quan hệ
sulphates	+0,381	+0,249	$4,4\times10^{-48}$	Có quan hệ
residual sugar	+0,026	+0,014	0,34	Chưa đủ bằng chứng về tương quan

Phân tích:

- Spearman cho bằng chứng về tương quan đơn điệu của alcohol, volatile acidity và sulphates với quality; đối với residual sugar ($\rho \approx 0{,}03$; $p \approx 0{,}34$), chưa đủ bằng chứng về tương quan đơn điệu. Không kết luận tương quan bằng không.
- Chênh lệch Spearman $\rho \approx 0{,}38$ và Pearson $r \approx 0{,}25$ của sulphates cho thấy hai cách đo quan hệ có kết quả khác nhau; chỉ riêng chênh lệch này chưa chứng minh mối quan hệ phi tuyến hay tồn tại điểm tối ưu.
- **Kiểm định nhiều lần:** nhóm làm 4 kiểm định cho 4 giả thuyết; nếu dùng ngưỡng chặt hơn 0,05/4 = 0,0125 (hiệu chỉnh Bonferroni) thì kết luận không đổi vì p của H1–H3 nhỏ hơn ngưỡng này rất nhiều.
- Tóm lại, ba phép kiểm định (t-test, Mann-Whitney, Spearman) đều cho cùng kết luận ở 4 giả thuyết.

Kiểm chứng thêm: "điểm trừ" và "điểm cộng"

Hình 6 gợi ý rằng volatile acidity và alcohol có khả năng phân biệt các mức điểm chất lượng khác nhau. Đây là phát hiện hậu nghiệm trên dữ liệu quan sát, không chứng minh một biến quyết định rượu bị chấm kém hoặc trở thành rượu ngon.

Bảng 3.8: So sánh trung vị giữa rượu lỗi, rượu đạt và rượu ngon (Mann-Whitney)

Biến	Trung vị lỗi (≤ 4)	Trung vị đạt (5–6)	Trung vị ngon (≥ 7)	p lỗi – đạt	p đạt – ngon
alcohol	10,0	10,0	11,6	0,95	$3{,}6\times10^{-45}$
volatile acidity	0,68	0,535	0,37	$1{,}5\times10^{-9}$	$4{,}1\times10^{-25}$
sulphates	0,56	0,61	0,74	$5{,}0\times10^{-6}$	$5{,}2\times10^{-25}$

Phân tích:

- Alcohol: hai nhóm rượu lỗi và rượu đạt có trung vị quan sát cùng bằng 10,0% và $p \approx 0{,}95$, nghĩa là chưa phát hiện bằng chứng khác biệt phân bố theo Mann–Whitney. Rượu ngon có giá trị trung tâm cao hơn nhóm rượu đạt; không suy ra can thiệp tăng cồn tạo ra rượu ngon.
- **Độ chua bay hơi:** rượu lỗi cao hơn rõ rệt so với rượu đạt (0,68 so với 0,535; $p \approx 1{,}5\times10^{-9}$), và rượu đạt lại cao hơn rượu ngon ($p \approx 4{,}1\times10^{-25}$) → đây là yếu tố tách được rượu lỗi khỏi rượu đạt nên nhóm gọi là "điểm trừ"; ở rượu ngon, chỉ số này còn thấp hơn nữa.
- **Sulphates:** khác biệt có ý nghĩa ở cả hai cặp (0,56 → 0,61 → 0,74): rượu lỗi thường có sulphates thấp hơn - bổ sung cho Bảng 3.3 (quá nhiều cũng không tốt).

- Ý nghĩa thực tế: có thể theo dõi volatile acidity và alcohol như những chỉ báo liên quan đến chất lượng để xây dựng quy trình kiểm tra; mọi ngưỡng can thiệp sản xuất cần được xác thực bằng chuyên môn và thử nghiệm riêng.
- **Lưu ý:** đây là phát hiện rút ra sau khi quan sát dữ liệu (không phải giả thuyết đặt từ đầu) và nhóm rượu lỗi chỉ có 63 chai, nên cần được kiểm chứng thêm trên dữ liệu mới.

3.6. Kiểm chứng kết quả bằng mô hình học máy

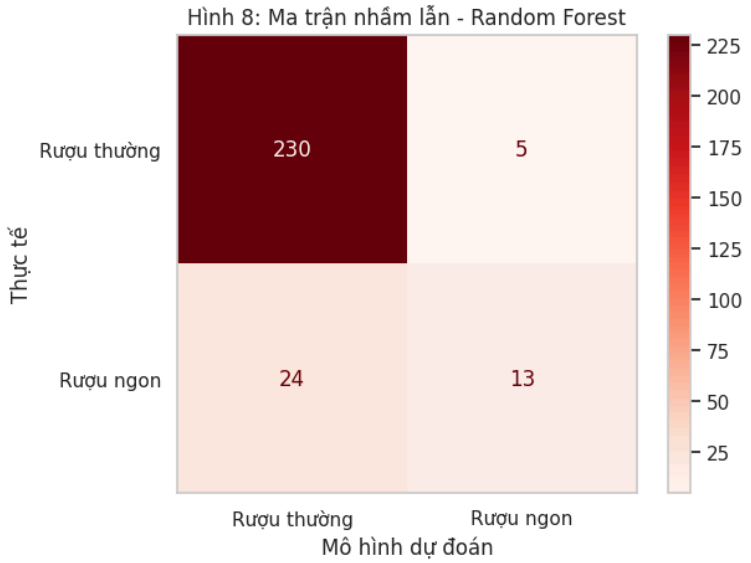
Mục đích: các mục 3.2–3.5 phân tích từng chỉ số riêng lẻ. Ở đây nhóm dùng một mô hình học máy xem xét **cả 11 chỉ số cùng lúc** để trả lời hai câu hỏi: (1) các chỉ số hóa lý có thực sự giúp phân biệt rượu ngon (điểm ≥ 7) với rượu thường không; (2) khi tự học từ dữ liệu, mô hình có đánh giá các yếu tố quan trọng giống kết luận ở phần kiểm định không. Ngoài ra, nhóm phân tích các trường hợp mô hình đoán sai để hiểu giới hạn của dữ liệu.

Vì sao chọn Random Forest (đã học ở bài giảng T14): mô hình gồm nhiều cây quyết định cùng "bỏ phiếu" nên kết quả ổn định; không cần chuẩn hóa dữ liệu và ít bị ảnh hưởng bởi outlier (phù hợp với quyết định giữ outlier ở mục 2.3); đồng thời cho biết mức độ quan trọng của từng chỉ số để nhóm đối chiếu với kết quả kiểm định.

Cách làm: mô hình chỉ được học trên 80% dữ liệu (tập train: 1.087 chai, 147 chai ngon); 20% còn lại (tập test: 272 chai, 37 chai ngon) được giữ riêng để kiểm tra, mô hình không được thấy phần này khi học. Dữ liệu được chia phân tầng (stratify) để tỷ lệ rượu ngon ở hai phần như nhau; tham số class_weight = "balanced" giúp mô hình chú ý hơn tới nhóm rượu ngon vốn rất ít. Kiểm định chéo 5-fold chỉ thực hiện trên tập train với các mô hình Dummy, Logistic Regression và Random Forest; tập test giữ riêng để trình bày hiệu năng cuối cùng của Random Forest.

3.6.1. Mô hình có phân biệt được rượu ngon không?

Mô hình Random Forest (300 cây, class_weight="balanced", random_state=42) đạt Accuracy 89,34% trên 272 mẫu test. Mức dự báo tất cả là rượu thường cũng đạt 86,40% do mất cân bằng lớp. Vì vậy, nhóm đánh giá bổ sung Precision, Recall, F1-score, Balanced Accuracy, Average Precision (AP) và ROC-AUC trên tập test, đồng thời so sánh các mô hình bằng kiểm định chéo phân tầng 5-fold trên tập train.



Hình 8: Ma trận nhầm lẫn của Random Forest trên tập test

Phân tích:

- 230 chai thường được đoán đúng; 13 chai ngon được tìm ra đúng; chỉ 5 chai thường bị đoán nhầm là ngon, nhưng có tới 24 chai ngon bị bỏ sót.
- Trong 18 chai mô hình chọn là "ngon", có **13 chai ngon thật (72,2%)**, trong khi chọn ngẫu nhiên chỉ được **13,6%** → mô hình chọn đúng rượu ngon **gấp khoảng 5 lần**.
- Tuy nhiên, mô hình chỉ tìm ra **13/37 chai ngon (35%)** → mô hình chọn ít nhưng khá chính xác, và bỏ sót phần lớn rượu ngon.
- Kết luận câu hỏi 1: Random Forest đạt Precision 72,22% nhưng Recall chỉ 35,14% và F1-score 47,27% đối với rượu ngon; Balanced Accuracy đạt 66,50%, AP đạt 59,39% và ROC-AUC đạt 88,33%. Mô hình có khả năng xếp hạng các mẫu theo nguy cơ/chất lượng nhưng bỏ sót phần lớn mẫu rượu ngon ở ngưỡng phân loại mặc định. Do đó, không nên coi Accuracy 89,34% là đủ để xác nhận hiệu quả sàng lọc trong thực tế. Kết quả đối chứng bằng kiểm định chéo phân tầng được trình bày ngay sau đây.

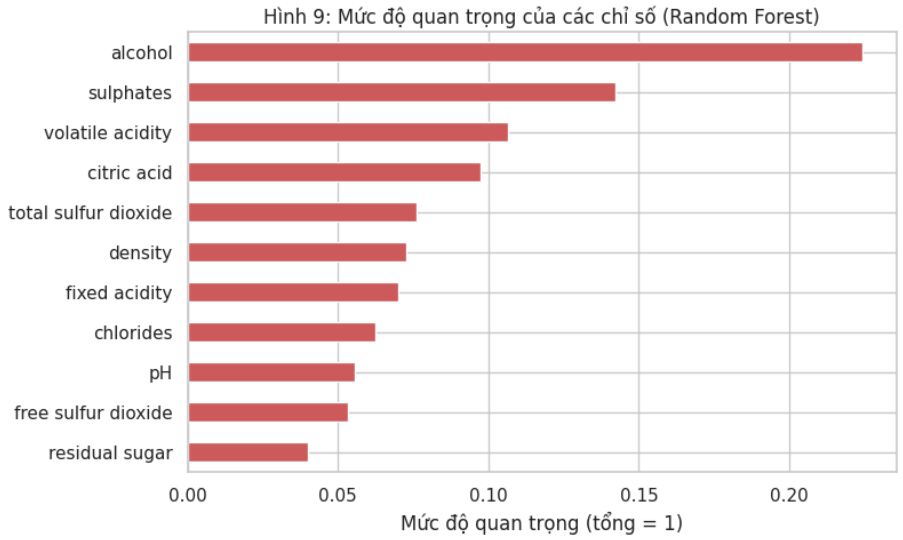
3.6.2. Đối chứng mô hình và đánh giá độ ổn định

Bảng 3.9: So sánh các mô hình bằng Stratified 5-Fold Cross-Validation (tập train)

Mô hình	F1	Recall	Balanced Accuracy	AP
Dummy	0.000	0.000	0.500	0.135
Logistic Regression	0.508	0.816	0.799	0.493
Random Forest	0.399	0.285	0.632	0.540

Bảng 3.9 trình bày các chỉ số trung bình qua 5 fold trên tập train (n=1.087), không phải kết quả tập test. Logistic Regression có Recall 0,816 và F1 0,508, cao hơn Random Forest (0,285; 0,399). Ngược lại, Random Forest có Average Precision 0,540, cao hơn Logistic Regression (0,493). Mô hình Dummy là đường cơ sở. Kết quả cho thấy việc lựa chọn mô hình phụ thuộc tiêu chí đánh giá và chi phí bỏ sót rượu ngon; chưa thực hiện tối ưu siêu tham số hay kiểm định trên tập dữ liệu độc lập mới.

3.6.3. Mô hình đánh giá yếu tố nào quan trọng?



Hình 9: Mức độ quan trọng của các chỉ số theo Random Forest

Bảng 3.10: Thứ hạng các yếu tố theo mô hình và theo hệ số tương quan

Thứ hạng	**Theo mô hình (Hình 9)**	**Theo tương quan (Hình 4)**
1	alcohol (22,4%)	alcohol (+0,48)
2	sulphates (14,2%)	volatile acidity (−0,39)
3	volatile acidity (10,7%)	sulphates (+0,25)
4	citric acid (9,7%)	citric acid (+0,23)
5	**residual sugar (4,0%)**	residual sugar (+0,01), gần bằng 0

Phân tích:

- Bốn biến đứng đầu của hai cách xếp hạng có điểm tương đồng, nhưng tương quan đơn biến và mức giảm impurity trong Random Forest đo những khía cạnh khác nhau, không xác nhận mức tác động nhân quả.
- Residual sugar có mức Feature Importance thấp trong mô hình này; chưa đủ bằng chứng để khẳng định đường dư không có tác động đến chất lượng.
- Kết luận câu hỏi 2: Các chỉ số hóa lý cung cấp thông tin phục vụ dự báo chất lượng. Tuy nhiên, độ quan trọng theo Random Forest là thước đo dự báo, không

phải bằng chứng về tác động nhân quả. Kiểm tra thêm bằng Permutation Importance (chấm điểm Average Precision) cho thấy alcohol và sulphates đứng đầu trên tập test, nhưng giá trị có thể dao động do tương quan giữa biến và số mẫu rượu ngon nhỏ.

Bảng 3.11: Độ quan trọng hoán vị trên tập test (Permutation Importance)

Biến	Giảm AP trung bình	Độ lệch chuẩn
alcohol	0.2309	0.0418
sulphates	0.1420	0.0469
volatile acidity	0.0867	0.0399
density	0.0661	0.0261
residual sugar	0.0555	0.0150
citric acid	0.0409	0.0359
chlorides	0.0378	0.0224
fixed acidity	0.0243	0.0266
total sulfur dioxide	0.0171	0.0261
pH	0.0091	0.0214
free sulfur dioxide	0.0005	0.0286

Mỗi biến được hoán vị 30 lần trên tập test; độ quan trọng là mức giảm Average Precision (AP) trung bình và độ lệch chuẩn giữa các lần hoán vị. Alcohol (0,2309), sulphates (0,1420) và volatile acidity (0,0867) có mức giảm AP lớn nhất. Chỉ số này đo mức đóng góp vào hiệu năng dự báo trong cấu hình đang xét, không phải tác động nhân quả. Kết quả nhạy với tương quan giữa các biến và cỡ mẫu test nhỏ; không sử dụng phép đánh giá này để tiếp tục tinh chỉnh mô hình trên test.

3.6.4. Phân tích lỗi: mô hình sai ở đâu và vì sao?

Bảng 3.12: Tỷ lệ đoán sai theo điểm chất lượng

Điểm chất lượng	Số chai (test)	Số chai đoán sai	Tỷ lệ sai
3	2	0	0%
4	14	0	0%
5	109	1	0,9%
6	110	4	3,6%
7	33	23	**69,7%**
8	4	1	25%

- Mô hình không sai chai nào ở điểm 3 và 4, chỉ sai 0,9% ở điểm 5 và 3,6% ở điểm 6 → rượu kém và rượu trung bình gần như **không bị nhầm thành rượu ngon**. Tập test chỉ có 2 chai điểm 3, 14 chai điểm 4 và 4 chai điểm 8, nên tỷ lệ sai ở các mức này mới là tín hiệu ban đầu.

- Gần như toàn bộ lỗi nằm ở **rượu điểm 7**: 23/33 chai (69,7%) bị bỏ sót; ở điểm 8 sai 1/4 chai. Điểm 7 nằm ngay trên ranh giới với điểm 6 (chỉ cách 1 điểm cảm quan), và nhiều chai 7 điểm có số liệu hóa học gần giống chai 6 điểm nên bị xếp vào nhóm thường.

Bảng 3.13: Hồ sơ hóa học trung bình của các nhóm đoán đúng/sai

Thực tế	Mô hình dự đoán	Số chai	Alcohol (%)	Volatile acidity	Sulphates
Ngon	Ngon	13	12,154	0,393	0,787
Ngon	Thường (bỏ sót)	24	11,346	0,429	0,736
Thường	Ngon (nhầm)	5	11,480	0,296	0,774
Thường	Thường	230	10,254	0,557	0,646

Vì sao mô hình nhầm?

- 24 chai ngon bị bỏ sót có nồng độ cồn trung bình chỉ **11,3%**, thấp hơn rõ so với **12,2%** của 13 chai ngon được tìm ra (sulphates cũng thấp hơn: 0,736 so với 0,787) → số liệu của chúng gần với rượu thường hơn.
- Ngược lại, 5 chai thường bị nhầm là ngon có hồ sơ hóa học **rất tốt** (cồn 11,48%, độ chua bay hơi chỉ 0,296 - thấp nhất trong cả 4 nhóm), tốt hơn cả những chai ngon bị bỏ sót, nhưng chuyên gia vẫn chỉ cho 6 điểm (nhóm này chỉ có 5 chai nên cần thận trọng).
- **Nhận xét: ở vùng ranh giới 6–7**, 11 chỉ số hóa lý **chưa đủ để giải thích** vì sao chuyên gia cho điểm khác nhau. Sự khác biệt có thể đến từ các yếu tố không có trong dữ liệu như mùi hương, hậu vị hay cảm nhận chủ quan của người chấm.
- Ứng dụng: Random Forest chỉ phù hợp để hỗ trợ xếp hạng và sàng lọc sơ bộ, chưa phù hợp để tự động loại bỏ lô rượu ngon do Recall thấp. Trong đối chứng kiểm định chéo, Logistic Regression có Recall và F1 trung bình cao hơn, còn Random Forest có AP trung bình cao hơn. Việc lựa chọn thuật toán phải gắn với mục đích: tránh bỏ sót rượu ngon hay ưu tiên tỷ lệ chính xác trong số mẫu được chọn và cần được xác thực trên dữ liệu mới.

3.7. Tổng hợp kết quả theo từng giả thuyết

Bảng 3.14 tổng hợp lại các bằng chứng đã có ở mục 3.2–3.6 cho từng giả thuyết.

Bảng 3.14: Tổng hợp bằng chứng và kết luận theo từng giả thuyết

Giả thuyết	Bằng chứng chính	Xem tại	Kết luận
H1 – Nồng độ cồn cao → điểm cao	r = +0,48 (mạnh nhất), Spearman ρ = +0,49; rượu ngon 11,55% so với 10,26% (+12,6%); t-test p ≈ $2{,}0\times10^{-40}$, Mann-Whitney p ≈ $1{,}2\times10^{-45}$; quan trọng nhất trong mô hình (22,4%)	Hình 4–6, 9; Bảng 3.2, 3.4, 3.6, 3.7	Được ủng hộ - yếu tố mạnh nhất
H2 – Độ chua bay hơi cao → điểm thấp	r = −0,39, ρ = −0,39; rượu ngon 0,406 so với 0,549 (−26,0%); t-test p ≈ $6{,}5\times10^{-28}$, Mann-Whitney p ≈ $8{,}0\times10^{-27}$; hạng 3 trong mô hình (10,7%)	Hình 4–6, 9; Bảng 3.2, 3.4, 3.6, 3.7	Được ủng hộ
H3 – Sulphates cao → điểm cao	r = +0,25 nhưng ρ = +0,38 (cần kiểm tra hình dạng quan hệ); rượu ngon 0,746 so với 0,645 (+15,6%); t-test p ≈ $1{,}9\times10^{-17}$; tỷ lệ rượu ngon cao nhất ở 0,75–0,85 (34,6%) rồi giảm khi > 1,0 (16,7%); hạng 2 trong mô hình (14,2%)	Hình 4, 5, 9; Bảng 3.2, 3.3, 3.4, 3.7	Được ủng hộ ở mức vừa phải - quá nhiều không tốt hơn
H4 – Khảo sát liên hệ đường dư	r = +0,01, ρ = +0,03; rượu ngon 2,70 so với 2,50; t-test p = 0,056, Mann-Whitney p = 0,054, Spearman p = 0,34; các hộp chồng lên nhau; xếp cuối trong mô hình (4,0%)	Hình 4, 5, 9; Bảng 3.2, 3.4, 3.6, 3.7	Chưa đủ bằng chứng ở mức 5% - chưa có bằng chứng về ảnh hưởng
Phát hiện thêm – độ chua bay hơi là "điểm trừ", nồng độ cồn là "điểm cộng"	Cồn: rượu lỗi và rượu đạt bằng nhau (10,0%; p = 0,95), rượu ngon cao hơn (p ≈ $3{,}6\times10^{-45}$). Độ chua bay hơi: rượu lỗi cao hơn rượu đạt (0,68 so với 0,535; p ≈ $1{,}5\times10^{-9}$)	Hình 6; Bảng 3.8	Được kiểm chứng - rút ra từ dữ liệu, cần kiểm tra thêm

Nhận xét:

- Các phép kiểm định và Random Forest cung cấp những bằng chứng bổ trợ về liên hệ thống kê hoặc năng lực dự báo; chúng không đồng nghĩa và không chứng minh quan hệ nhân quả.
- Theo mức tương quan đơn biến, alcohol và volatile acidity có độ lớn nổi bật; kết quả này không được coi là bảng xếp hạng mức ảnh hưởng độc lập của các yếu tố.

GIAI ĐOẠN 4: ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ

4.1. Tóm tắt các phát hiện nổi bật

Bảng 4.1: Các phát hiện chính

	Phát hiện	Bằng chứng
1	**Nồng độ cồn** là yếu tố quan trọng nhất, là "điểm cộng" giúp rượu trở thành rượu ngon	Tương quan +0,48; rượu ngon nhiều cồn hơn 12,6%; rượu lỗi và rượu đạt cùng trung vị cồn ($p = 0,95$) nhưng rượu ngon cao hơn rõ ($p \approx 3,6\times10^{-45}$, Bảng 3.8); đứng đầu trong mô hình (22,4%)
2	**Độ chua bay hơi** là "điểm trừ" lớn nhất, quyết định rượu có bị chấm kém	Tương quan −0,39; tách rõ rượu lỗi khỏi rượu đạt (trung vị 0,68 so với 0,535; $p \approx 1,5\times10^{-9}$, Bảng 3.8); nồng độ cồn không tách được hai nhóm này
3	**Sulphates** có lợi ở mức vừa phải (khoảng 0,65–0,85)	Rượu ngon cao hơn 15,6%; tỷ lệ rượu ngon cao nhất (34,6%) ở khoảng 0,75–0,85 rồi giảm còn 16,7% khi > 1,0 (Bảng 3.3); Spearman (0,38) cao hơn Pearson (0,25) → quan hệ cần kiểm tra hình dạng quan hệ; quan trọng thứ 2 trong mô hình
4	**Độ ngọt** chưa có bằng chứng ảnh hưởng đến chất lượng rượu vang đỏ	Tương quan 0,01; p-value t-test 0,056, Spearman 0,34; xếp cuối trong mô hình (4,0%)
5	Quy tắc **cồn > 11% và độ chua bay hơi < 0,5** tăng tỷ lệ gặp rượu ngon từ 7,7% lên 43,2%	Hình 7 (ngưỡng chọn từ chính dữ liệu, cần kiểm tra thêm)
6	**Mô hình học máy xác nhận** các kết luận trên; hầu như không nhầm rượu thường thành rượu ngon, nhưng **bỏ sót nhiều rượu điểm 7** (vùng ranh giới 6–7)	Hình 8–9, Bảng 3.9–3.11; chọn đúng 72,2% nhưng chỉ tìm ra 13/37 chai ngon

4.2. Khuyến nghị ứng dụng thực tế

Đối với nhà sản xuất rượu vang:

1. Ưu tiên theo dõi độ chua bay hơi trong giám sát chất lượng kết hợp kiểm tra cảm quan. Không sử dụng riêng ngưỡng 0,5 g/dm³ trong nghiên cứu này để ấn định tiêu chuẩn kỹ thuật bắt buộc.

2. Nồng độ cồn có tương quan dương với điểm chất lượng trong mẫu. Không khuyến nghị chủ động nâng nồng độ cồn lên ≥11% nếu chưa có thử nghiệm kỹ thuật và bằng chứng nhân quả.
3. Đối với sulphates, chỉ ghi nhận mối liên hệ thống kê theo các khoảng quan sát. Sulphates không đồng nghĩa với SO_2/sulfites bảo quản; không khuyến nghị liều lượng 0,65–0,85 g/dm³ trên cơ sở dữ liệu này.
4. Chưa có cơ sở để ưu tiên điều chỉnh đường dư chỉ dựa trên phân tích này; tiếp tục theo dõi theo tiêu chuẩn sản phẩm.
5. Kết hợp phân tích hóa lý, đánh giá cảm quan và mô hình dự báo để nghiên cứu khả năng hỗ trợ sàng lọc; mô hình hiện chỉ nhận diện đúng 13/37 mẫu ngon (recall 35,1%), chưa đủ để thay thế đánh giá chuyên gia.

Đối với nhà nhập khẩu, phân phối (ví dụ doanh nghiệp nhập khẩu rượu vào Việt Nam):

6. Quy tắc hai chỉ số (alcohol > 11%, volatile acidity < 0,5) chỉ là giả thuyết sàng lọc. Tỷ lệ cao gấp 5,6 lần được tính từ chính mẫu dùng để lựa chọn ngưỡng, chưa phải là hiệu quả đã được xác nhận trên các lô mới.

4.3. Giới hạn của tập dữ liệu

- **Phạm vi hẹp:** chỉ gồm rượu vang đỏ Vinho Verde của Bồ Đào Nha, kết luận chưa chắc đúng với vùng hoặc giống nho khác.
- **Thiếu thông tin kinh tế:** không có giá bán, thương hiệu, giống nho, năm sản xuất (bị ẩn vì lý do bảo mật).
- **Thiếu thông tin cảm quan:** phân tích lỗi cho thấy 11 chỉ số hóa lý chưa đủ để phân biệt rượu 6 điểm và 7 điểm; dữ liệu không có mùi hương, hậu vị.
- **Điểm chất lượng mang tính chủ quan** do chuyên gia nếm thử chấm.
- Quy tắc hai chỉ số được chọn hậu nghiệm trên toàn bộ dữ liệu, vì vậy, kết quả 43,2% trong mẫu không phải là hiệu quả dự báo ngoài mẫu. Cần xây dựng và xác nhận ngưỡng trên dữ liệu độc lập.
- **Mất cân bằng:** rất ít mẫu điểm 3 (10 mẫu) và điểm 8 (17 mẫu, sau khi xóa trùng); tập test chỉ có 37 chai ngon nên kết quả mô hình có thể dao động nếu chia dữ liệu theo cách khác.
- **Tương quan không phải nhân quả:** dữ liệu chỉ cho biết các yếu tố đi cùng nhau, chưa chứng minh tăng cồn sẽ gây ra điểm cao hơn.

4.4. Hướng mở rộng trong tương lai

- Bổ sung dữ liệu rượu vang trắng (4.898 mẫu) và giá bán để đánh giá hiệu quả kinh tế.

- Thu thập thêm dữ liệu cảm quan (mùi hương, hậu vị) để giải thích vùng ranh giới 6–7.
- Phát triển mô hình thành công cụ dự đoán chất lượng cho lô hàng mới (đánh giá kỹ hơn bằng nhiều lần chia dữ liệu).
- Dự đoán **chính xác từng mức điểm** bằng mô hình thứ bậc (ordinal) khi có thêm mẫu điểm 3–4 và 8.
- Thực hiện thí nghiệm có kiểm soát trong sản xuất để kiểm chứng quan hệ nhân quả.

KẾT LUẬN

Qua bốn giai đoạn, nhóm nghiên cứu 1.599 quan sát ban đầu và sử dụng 1.359 quan sát sau khi loại bỏ bản ghi trùng lặp theo toàn bộ thuộc tính (một giả định xử lý dữ liệu cần được xác minh thêm). Kết quả cho thấy alcohol, volatile acidity và sulphates có mối liên hệ thống kê với điểm chất lượng; chưa đủ bằng chứng để khẳng định residual sugar không có ảnh hưởng. Đồng thời, nhóm nhận thấy chưa đủ căn cứ để đưa ra suy luận về quan hệ nhân quả hoặc mức sulphates tối ưu từ bộ dữ liệu quan sát. Random Forest đạt Accuracy 89,34%, Precision 72,22%, Recall 35,14%, F1 47,27%, AP 59,39% và ROC-AUC 88,33% trên tập test. So sánh kiểm định chéo phân tầng 5-fold trên tập train cho thấy Logistic Regression đạt Recall và F1 trung bình cao hơn Random Forest trong cấu hình kiểm tra, nhấn mạnh nhu cầu lựa chọn thuật toán theo mục tiêu vận hành.

TÀI LIỆU THAM KHẢO VÀ MÃ NGUỒN

- Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Modeling wine preferences by data mining from physicochemical properties. Decision Support Systems, 47(4), 547–553.
- Kaggle – Red Wine Quality: https://www.kaggle.com/datasets/uciml/red-wine-quality-cortez-et-al-2009
- Bài giảng học phần Khoa học dữ liệu (làm sạch dữ liệu, trực quan hóa dữ liệu, các mô hình học máy có giám sát).

Mã nguồn (GitHub):
https://github.com/Minhille/NH-M-11---KT-T-CLC66B---KHOA-H-C-D-LI-U---7.git